

Recomendação de treinos personalizados em academia

AP1 — Fundamentos de Inteligência Artificial · ADS/ULBRA

Vinicius Casagrande · 03/09/2026

1. O problema e para quem

Montar um treino adequado exige cruzar várias informações do aluno ao mesmo tempo: objetivo, experiência, disponibilidade, restrições físicas e equipamento disponível.

Feito manualmente, não escala para muitos alunos e fica inconsistente entre profissionais.

Público: alunos de academia e profissionais de educação física que precisam sugerir treinos de forma rápida e padronizada.

Por que IA: o padrão perfil → treino pode ser aprendido a partir de exemplos e aplicado de forma consistente e escalável.

2. Tipo de problema, entradas e saídas

Classificação supervisionada — prever uma categoria a partir de exemplos rotulados.

Entrada: perfil do aluno — idade, objetivo, nível de experiência, dias disponíveis por semana, restrição física, equipamento disponível.

Saída: uma de 4 categorias — Treino A (musculação/hipertrofia), B (cardio + circuito), C (funcional), D (peso corporal adaptado).

Soluções semelhantes: Fitbod e BodBot — apps que geram treinos por perfil, mas ajustam a cada sessão de cada usuário. Aqui: um classificador único treinado sobre vários alunos.

3. Abordagem escolhida: Árvore de Decisão

Comparada a: sistema de regras fixas ("se... então...") escrito à mão.

Regras puras seriam insuficientes: ~8% dos casos da base fogem do padrão previsto, e manter a árvore de regras manualmente não escala nem se adapta a dados novos.

A Árvore de Decisão aprende os padrões a partir dos dados, lida bem com atributos categóricos (a maioria aqui) e continua interpretável — dá para ver as regras que ela extraiu.

Escopo do semestre: entregar o classificador treinado e avaliado. Fora do escopo: app, ajuste por sessão, prescrição de exercícios individuais.

4. Base de dados e origem

Arquivo: `dataset_academia.csv` — 300 linhas × 8 colunas.

Origem: base simulada, gerada em Python (pandas + numpy) com seed fixa 1053, a partir de distribuições plausíveis e regras de associação perfil → treino, com 8% de ruído.

Licença: dataset próprio, uso livre para fins acadêmicos. Reprodutível pelo script `gerar_dataset.py`.

6 variáveis de entrada (features) + 1 variável de saída (`treino_recomendado`).

Limitação assumida: ainda não há dados reais de alunos — substituição prevista para os próximos encontros.

5. Dicionário de dados (resumo)

Variável	Tipo	Valores	Papel
idade	num. discreta	16–51 anos	entrada
objetivo	categ. nominal	Emagrecimento / Hipertrofia / Condicionamento	entrada
nivel_experiencia	categ. ordinal	Iniciante / Intermediário / Avançado	entrada
dias_disponiveis_semana	num. discreta	1–6 dias	entrada
restricao_fisica	categ. nominal	Nenhuma / Joelho / Ombro / Lombar	entrada
equipamento_disponivel	categ. ordinal	Nenhum / Limitado / Completo	entrada
treino_recomendado	categ. nominal	Treino A / B / C / D	SAÍDA (label)
aluno_id	num. discreta	1–300	só identificação

6. Análise inicial


Idade média ~29 anos (16 a 51) — público jovem adulto, mas disperso.

Maioria treina 3–4 dias por semana; extremos (1 e 6) pouco frequentes.

Maioria: iniciante (54%) e sem restrição física (69%).

Classe de saída (gráfico): Treino D 30,7% → Treino B 18,0%.

Leitura: a base cobre bem o aluno típico e mal os perfis de extremo.



7. Diagnóstico de qualidade da base

Dimensões: 300×8 . Ausentes: 0 (0%) — mas isso é artificial da simulação.

Duplicados: 0 linhas idênticas, 0 aluno_id repetido (7 colisões de perfil, esperadas).

Inconsistências: nivel_experiencia sem acento vs dicionário; ordinais como texto; dicionário diz idade até 65, base vai até 51; 8% de ruído de rótulo (24 registros).

Desbalanceamento: leve — 1,7:1 entre Treino D e Treino B.

Ações previstas p/ Encontro 8: padronização, codificação ordinal, class_weight + split estratificado, pipeline de ingestão prevendo nulos.

Viés identificado (parte do diagnóstico)

Grupo "sem acesso a equipamento": só 7,3% da base — e 20 de 22 desses alunos recebem Treino D por força da própria regra que gerou os dados.

Tipo: viés de amostragem + viés de rotulagem (o rótulo veio de uma regra do estudante, não de um profissional de educação física).

Impacto: o modelo nunca aprende a personalizar para quem treina em casa — grupo que correlaciona com menor poder aquisitivo. Pior serviço para quem tem menos acesso.

Mitigação: cota mínima para esse grupo na coleta real; avaliar métrica por subgrupo; documentar a limitação de forma visível para quem usar a ferramenta.

8. Próximos passos

Encontro 8 — preparação dos dados: padronizar categorias, codificar variáveis, tratar os problemas da tabela de diagnóstico, dividir treino/teste de forma estratificada.

Encontro 9 — treinar a Árvore de Decisão e avaliar por F1-macro e matriz de confusão (não só acurácia), analisando o desempenho por subgrupo.

Ao longo do semestre — buscar dados reais de alunos para substituir a base simulada e revalidar todo o diagnóstico.

Obrigado. Perguntas?

github.com/Vinicasagrande87/fundamentos_ia