

Fundamentos de Inteligência Artificial — ADS/ULBRA
Modelo Padrão de Entrega de Atividades

Atividade nº	4	Encontro	5 — 27/08/2026
Data	27/08/2026	Etapa	☒ Entrega final

Nome	Vinicius Casagrande
Domínio / tema do projeto	Academia — Recomendação de treinos e exercícios personalizados

1. O que foi feito nesta atividade

Esta entrega consolida e revisa a versão de esboço da Atividade 4, apresentando a base de dados do projeto, o dicionário de dados completo, a análise estatística inicial interpretada e a primeira visualização, além das observações sobre limitações da base que servirão de ponto de partida para o tratamento de dados dos Encontros 5 e 8. A base de dados foi mantida na sua versão simulada, já documentada com origem e critério de geração claros, e o dicionário, as estatísticas e a visualização foram revisados para maior precisão e clareza em relação ao esboço.

2. Artefato verificável

Link do repositório: https://github.com/Vinicasagrande87/fundamentos_ia

Arquivo da base de dados: dataset_academia.csv (300 registros, 8 colunas), anexado ao repositório

Notebook de análise: atividade4_academia.ipynb (executado, com saídas e gráficos visíveis, anexado ao repositório)

README.md: atualizado no repositório com a seção "Base de dados e dicionário de dados", contendo o dicionário completo, as estatísticas interpretadas, a visualização comentada e o backlog atualizado.

3. Base de dados

A base de dados é composta por 300 registros simulados de alunos de academia, com 8 colunas: aluno_id, idade, objetivo, nivel_experiencia, dias_disponiveis_semana, restricao_fisica, equipamento_disponivel e treino_recomendado.

3.1 Origem da base

A base é sintética, gerada em Python (pandas + numpy) a partir de distribuições estatísticas plausíveis para cada atributo (ex.: idade com distribuição aproximadamente normal; objetivo e nível de experiência com probabilidades definidas com base em premissas realistas para uma academia) e de regras de associação entre o perfil do aluno e o treino recomendado. Foi adicionado ruído aleatório de 8% para simular exceções reais que fogem do padrão de associação, como costuma acontecer em dados reais de academias. A geração está documentada e é reproduzível pelo script gerar_dataset.py versionado no repositório (seed fixa = 1053). Por se tratar de um dataset próprio, não há restrição de licença — uso livre para fins acadêmicos. Esta base será substituída por dados reais assim que o projeto tiver acesso a eles, previsto para os Encontros 5 e 8, quando o tratamento e a limpeza de dados serão trabalhados.

3.2 Dicionário de dados

Variável	Descrição	Tipo	Valores possíveis	Entr./Saída	Obs.
aluno_id	Identificador único do aluno simulado	Num. discreta	1 a 300	—	Não é feature
idade	Idade do aluno em anos	Num. contínua	16 a 65 anos	Entrada	Média ~29 anos
objetivo	Objetivo principal do aluno na academia	Categ. nominal	Emagrecimento, Hipertrofia, Condicionamento	Entrada	Sem ausentes
nivel_experiencia	Nível de experiência do aluno com treino	Categ. ordinal	Iniciante, Intermediário, Avançado	Entrada	Ordem implícita
dias_disponiveis_semana	Dias por semana disponíveis para treinar	Num. discreta	1 a 6 dias	Entrada	Média ~3,5
restricao_fisica	Restrição física relevante do aluno	Categ. nominal	Nenhuma, Joelho, Ombro, Lombar	Entrada	Maioria sem restrição
equipamento_disponivel	Nível de acesso a equipamentos de treino	Categ. ordinal	Completo, Limitado, Nenhum	Entrada	Reflete o local de treino
treino_recomendado	Categoria de treino recomendada	Categ. nominal	Treino A, B, C, D	Saída (label)	Variável-alvo

3.3 Variáveis de entrada e saída

O problema é de aprendizado supervisionado de classificação. As variáveis de entrada (features) são idade, objetivo, nivel_experiencia, dias_disponiveis_semana, restricao_fisica e equipamento_disponivel. A variável de saída (label/target) é treino_recomendado — a categoria de treino que o modelo deverá aprender a prever a partir do perfil do aluno. Essa variável foi escolhida por representar diretamente o resultado prático que o sistema deve entregar ao usuário final (a recomendação), e é consistente com a abordagem de Árvore de Decisão definida na Atividade 3, que lida bem com atributos majoritariamente categóricos como os presentes na base.

4. Análise estatística inicial (revisada e interpretada)

4.1 Variáveis numéricas

Variável	Média	Desvio padrão	Mínimo	Máximo
idade	29,29	7,71	16	51
dias_disponiveis_semana	3,44	1,27	1	6


Interpretação: a idade média dos alunos simulados é de aproximadamente 29,3 anos, com desvio padrão de aproximadamente 7,7 anos, variando de 16 a 51 anos — um público concentrado em jovens adultos, mas com dispersão relevante o suficiente para exigir que o modelo generalize bem entre faixas etárias distintas. O número médio de dias disponíveis por semana é de aproximadamente 3,5, com desvio padrão de 1,3 dia, indicando que a maior parte dos alunos treina entre 3 e 4 dias por semana, o que é uma faixa relativamente concentrada e pode limitar a capacidade do modelo de generalizar para perfis com disponibilidade muito baixa (1 dia) ou muito alta (6 dias), por serem menos representados na base.

4.2 Variáveis categóricas

Variável categórica	Contagem por categoria
objetivo	Hipertrofia: 114 · Emagrecimento: 103 · Condicionamento: 83
nivel_experiencia	Iniciante: 161 · Intermediário: 100 · Avançado: 39
restricao_fisica	Nenhuma: 208 · Joelho: 34 · Lombar: 34 · Ombro: 24
equipamento_disponivel	Completo: 168 · Limitado: 110 · Nenhum: 22
treino_recomendado (label)	Treino D: 92 · Treino C: 80 · Treino A: 74 · Treino B: 54

Interpretação: os objetivos ficaram relativamente equilibrados entre si, com leve predominância de Hipertrofia. A maioria dos alunos é iniciante (161 de 300) e não possui restrição física (208 de 300), o que é coerente com o perfil típico de quem frequenta academia. As quatro classes do label (treino recomendado) ficaram razoavelmente balanceadas — a diferença entre a classe mais frequente (Treino D, 92) e a menos frequente (Treino B, 54) é de apenas 38 registros — o que é favorável para o treinamento futuro do classificador, já que evita o problema de classes muito desbalanceadas, que tende a enviesar o modelo em favor da classe majoritária.

4.3 Visualização inicial



Foram geradas duas visualizações no notebook de análise, mostradas acima:

- Histograma da distribuição de idade dos alunos — mostra concentração entre 20 e 35 anos, com leve assimetria à direita, confirmando visualmente a média e o desvio padrão calculados.
- Gráfico de barras da contagem de treinos recomendados — mostra as quatro categorias com frequências relativamente próximas, com leve predominância dos treinos D (Peso Corporal Adaptado) e C (Funcional), refletindo o predomínio de alunos iniciantes e com objetivo de condicionamento na base simulada.

5. Primeiras observações sobre a base (ponto de partida para o Encontro 5)

- A base é 100% simulada — ainda não reflete o comportamento real de alunos, o que é a limitação mais relevante desta etapa.
- Não há valores ausentes na base simulada atual, mas essa característica é artificial (decorrente da geração sintética) e não deve ser assumida como garantida quando dados reais forem incorporados.
- A variável `dias_disponiveis_semana` está concentrada em torno de 3 a 4 dias, com poucos exemplos nos extremos (1 e 6 dias) — pode ser necessário balancear ou tratar esses casos na etapa de preparação dos dados.
- A limpeza e o tratamento mais aprofundado dos dados (outliers, normalização, codificação de variáveis categóricas para o modelo) não foram feitos nesta etapa, conforme orientado, e ficam para os Encontros 5 e 8.

6. Organização, dificuldades e observações (o que mudou em relação ao esboço)

Em relação ao esboço entregue em 20/08/2026, esta entrega final manteve a mesma base de dados e a mesma estrutura de dicionário, mas revisou e aprofundou os seguintes pontos:

- A justificativa da variável de saída (treino_recomendado) foi detalhada, explicando por que ela representa o resultado prático esperado pelo usuário e sua coerência com a abordagem de Árvore de Decisão.
- As interpretações das estatísticas descritivas foram ampliadas, indicando não só o que os números mostram, mas também possíveis implicações para a capacidade de generalização do modelo (ex.: baixa representação de dias extremos de disponibilidade).
- Foi incluída explicitamente a seção de "primeiras observações sobre a base", como ponto de partida para o tratamento de dados do Encontro 5.

A principal dificuldade da atividade foi a ausência de dados reais de alunos, contornada pela construção de uma base simulada com regras plausíveis e ruído controlado, documentando claramente esse critério para transparência da limitação.

7. Declaração de uso de Inteligência Artificial

Uso de IA nesta entrega: Sim

Ferramenta: Claude (Anthropic)

Utilização: a IA foi usada como apoio para gerar o script de simulação do dataset a partir dos critérios definidos por mim (variáveis do projeto de Academia e abordagem escolhida na Atividade 3), para construir e executar o notebook de análise exploratória, e para estruturar a redação deste documento e do README do repositório.

Produção própria: as decisões sobre quais variáveis compõem o perfil do aluno, o critério de geração dos dados simulados, a escolha da variável-alvo, a interpretação dos resultados estatísticos e as observações sobre limitações da base são minhas.