Recomendação de Treinos Personalizados em Academia

AS — Apresentação final do projeto

Vinicius Casagrande · Fundamentos de Inteligência Artificial · ADS / ULBRA · 19/11/2026

github.com/Vinicasagrande87/fundamentos_ia

O problema, quem é afetado e o que mudou desde a AP2

Critério 1 · Problema, evolução e contextualização

O problema

Sugerir o **treino inicial** (A musculação, B cardio + circuito, C funcional, D peso corporal adaptado) a partir de 6 dados da matrícula.

Usuário: **professor**. Afetado: **aluno**.

O erro que importa

Aluno que precisava do **Treino D** recebe um treino mais exigente.

Na academia: iniciante com dor lombar fazendo musculação → **lesão e desistência**.

Métrica principal: **recall de Treino D**: dos alunos que precisam do treino adaptado, quantos o recebem.

Na AP2 eu dizia	Hoje, medido
"Acerta 90%"	Foi sorte do sorteio: **0,86** na validação repetida (vai de 0,80 a 0,95)
"Balanced melhora o recall de D"	Não melhora (ganha 8, perde 10 em 50 folds). **Saiu**
Idade é só mais uma variável	**Atalho espúrio** que atendia pior jovens e mais velhos. **Saiu**
"Qual modelo acerta mais?"	**Onde** erra, **com quem**, e o que o professor precisa revisar

Os dados: sintéticos, e isso define o que o modelo pode provar

Critério 2 · Dados, preparação e diagnóstico de qualidade

300

alunos sintéticos, gerados por gerar_dataset.py (seed 1053)

8%

dos rótulos trocados de propósito (24 alunos)

0,92

teto de acurácia de qualquer modelo nesta base

Diagnóstico	Achado	Como afeta o resultado
Origem	Rótulo = regra escrita por mim + ruído. Nenhuma medição real	O modelo aprende **a minha regra**, não a de um profissional
Tratamento	Tirar aluno_id · padronizar texto · ordenar categorias (nada aprendido dos dados)	Sem vazamento antes do split. O notebook regera a base e confere: **idêntica**
Ausentes / desbalanceamento	Nenhum ausente · D 31%, B 18%	Chute fixo acerta 31%: esse é o **baseline**
Combinações raras	Algumas células com 5 a 20 alunos. Iniciantes com 12% de ruído	É **onde o modelo erra**: a limitação da base vira limitação do modelo

O modelo: o que eu testei e por que fiquei com a árvore

Critério 3 · Modelo, treinamento e justificativa técnica · validação cruzada 5 folds × 10 repetições, mesmos folds para todos

Modelo	Acurácia	Recall de D	Recall de D fora da regra	Decisão
Baseline (sempre o treino mais comum)	0,31	1,00	1,00	Referência: manda todos para D
Árvore profundidade 5, com idade (AP2)	0,83	0,77	0,59	Substituída
Árvore profundidade 5 balanced, sem idade (Ativ. 15)	0,84	0,78	0,60	Substituída
Rede neural MLP (16 neurônios), sem idade	0,86	0,86	0,82	Descartada
Árvore profundidade 6, sem idade (FINAL)	**0,86**	**0,84**	**0,89**	**Escolhida**

Por que árvore e não rede neural

Fora da regra, a árvore **ganha nas 10 repetições** (+0,07).

Na acurácia, **empatam** (5 × 2 × 3).

A árvore **mostra as regras**: o professor pode conferir, e foi assim que achei o erro.

Suposições do algoritmo

Cortes "se... então", uma variável por vez: **vale**, porque a regra real é assim.

Não precisa normalizar.

Falha: poucas amostras por folha. Algumas folhas decoram ruído (treino 0,93 > teto 0,92).

Lendo as regras da árvore, achei um ramo que ela não alcançava

Critérios 3 e 5 · Explicabilidade (export_text) usada para corrigir o modelo

Árvore profundidade 5

Hipertrofia → sem restrição → com equipamento → **Treino A para todos**

A regra real tem a exceção: **iniciante com ≤ 2 dias → Treino D**.

Para perguntar "é iniciante?" a árvore precisa do **6º nível**. Com 5, não chega.

Árvore profundidade 6

… → dias ≤ 2 → **é iniciante? → Treino D**

Recall de D da hipertrofia: **0,54 → 0,82**

Era erro de **capacidade**, não de falta de dados. Por isso a rede neural acertava esses casos.

Profundidade	4	5	6	7	8	sem limite
Acurácia	0,86	0,85	0,86	0,85	0,84	0,84
Recall de D fora da regra	0,67	0,68	0,89	0,90	0,90	0,90
Acurácia no treino	0,87	0,90	0,93	0,94	0,94	0,95

A partir da 7, o recall de D para de melhorar e a acurácia de validação cai: as folhas a mais só decoram ruído.

Resultado: quase 3 vezes o baseline, a 6 pontos do teto

Critério 4 · Avaliação, métricas e interpretação · média de 10 repetições de validação cruzada 5 folds

0,31

baseline: sempre "Treino D"

0,86

acurácia do modelo final

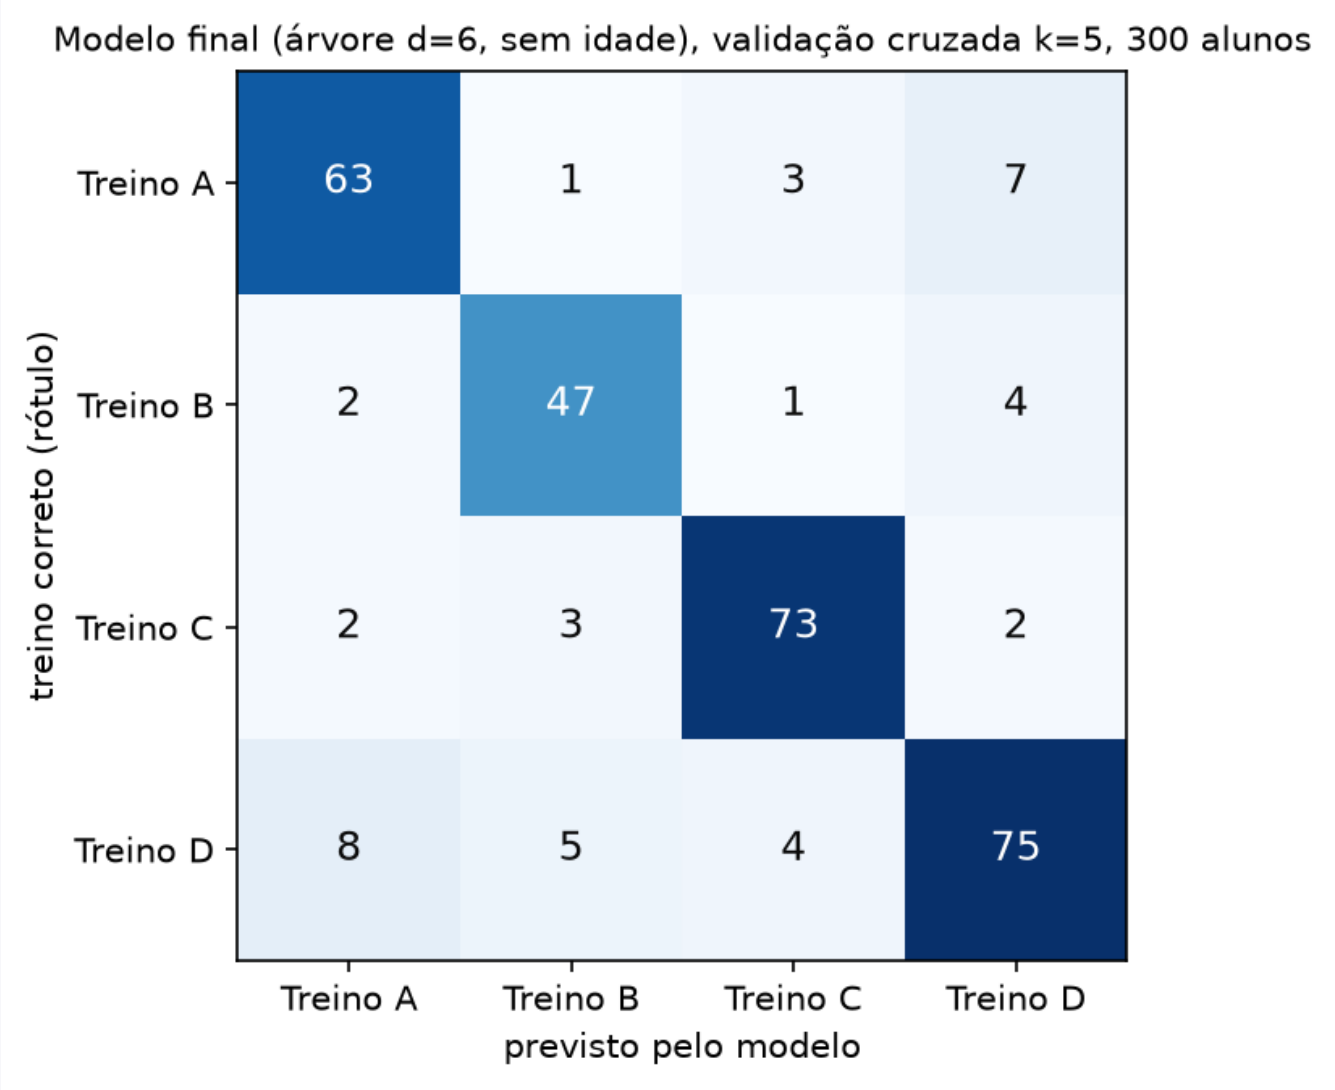
0,84

recall de Treino D (métrica principal)

Número	Em linguagem simples
Acurácia 0,86	De cada 100 alunos, **86 recebem o treino correto**. O chute fixo acerta 31.
Recall de D 0,84	De cada 100 alunos que precisam do treino adaptado, **84 o recebem**.
Baseline: recall de D 1,00	Truque: manda **todo mundo** para D e por isso erra 7 de cada 10 alunos no geral.
Precisão de D 0,85	Quando sugere o treino adaptado, 85% das vezes era o caso.
Split único: 0,80 a 0,95	O mesmo modelo em 30 sorteios diferentes. O 0,90 da AP2 foi sorte, e **a média é o número**.

Para onde vão os erros caros

Critério 4 · matriz de confusão do modelo final (validação cruzada 5 folds, 300 alunos)



Olhe a última linha

Dos **92** alunos que precisavam de D, **75** receberam.

Dos 17 que não receberam, **8 foram para musculação**: carga em quem precisava de adaptação.

Erro	Na academia	Custo
Precisava de D, recebeu A/B/C	Risco de lesão	**Alto**
Recebeu D sem precisar	Treino leve demais, ajustado na 1ª semana	Baixo
Troca entre A, B e C	Progresso mais lento	Médio

A regra de segurança muda o que a métrica mede, então separei

Critérios 4 e 5 · Regra: restrição física + iniciante, ou sem equipamento → revisão do professor (sugestão: Treino D)

O problema (feedback da Atividade 14): a regra copia um trecho da regra que **gerou os rótulos**. Nos 72 alunos cobertos, a regra de geração manda D para **todos**.

Lá dentro, ela acerta **por construção**. Somar esse acerto ao do modelo (0,95) mediria a regra concordando consigo mesma.

Recorte (validação cruzada, 300 alunos)	Alunos	Alunos D	Recall de D	Falsos negativos de D
FORA da cobertura: o modelo decide (número do modelo)	**228**	**30**	**0,83**	**5**
Dentro da cobertura: o que a árvore faria sozinha	72	62	0,81	12
Dentro da cobertura: a regra (circular nesta base)	72	62	1,00	0

24%

dos alunos vão para a fila do professor: é custo, não acerto

O que reporto como desempenho do modelo: o número de fora da cobertura.

O que só se mede com alunos reais: o ganho da regra, comparado com a decisão do professor.

A explicabilidade também mostrou onde a árvore é perigosa

Critério 5 · regras da árvore final impressas com export_text (notebook, §9)

Duas folhas que decoraram ruído

Hipertrofia + **restrição no joelho + iniciante** + ≤ 2 dias → **Treino A** (musculação)

Condicionamento + **restrição + iniciante** + ≤ 2 dias → **Treino A** (musculação)

A regra real manda os dois para **Treino D**. Na academia: iniciante machucado fazendo treino de carga.

Por que a regra de segurança fica

Os dois perfis estão **dentro da cobertura** da regra.

Eles **nunca** recebem a previsão automática: vão para o professor.

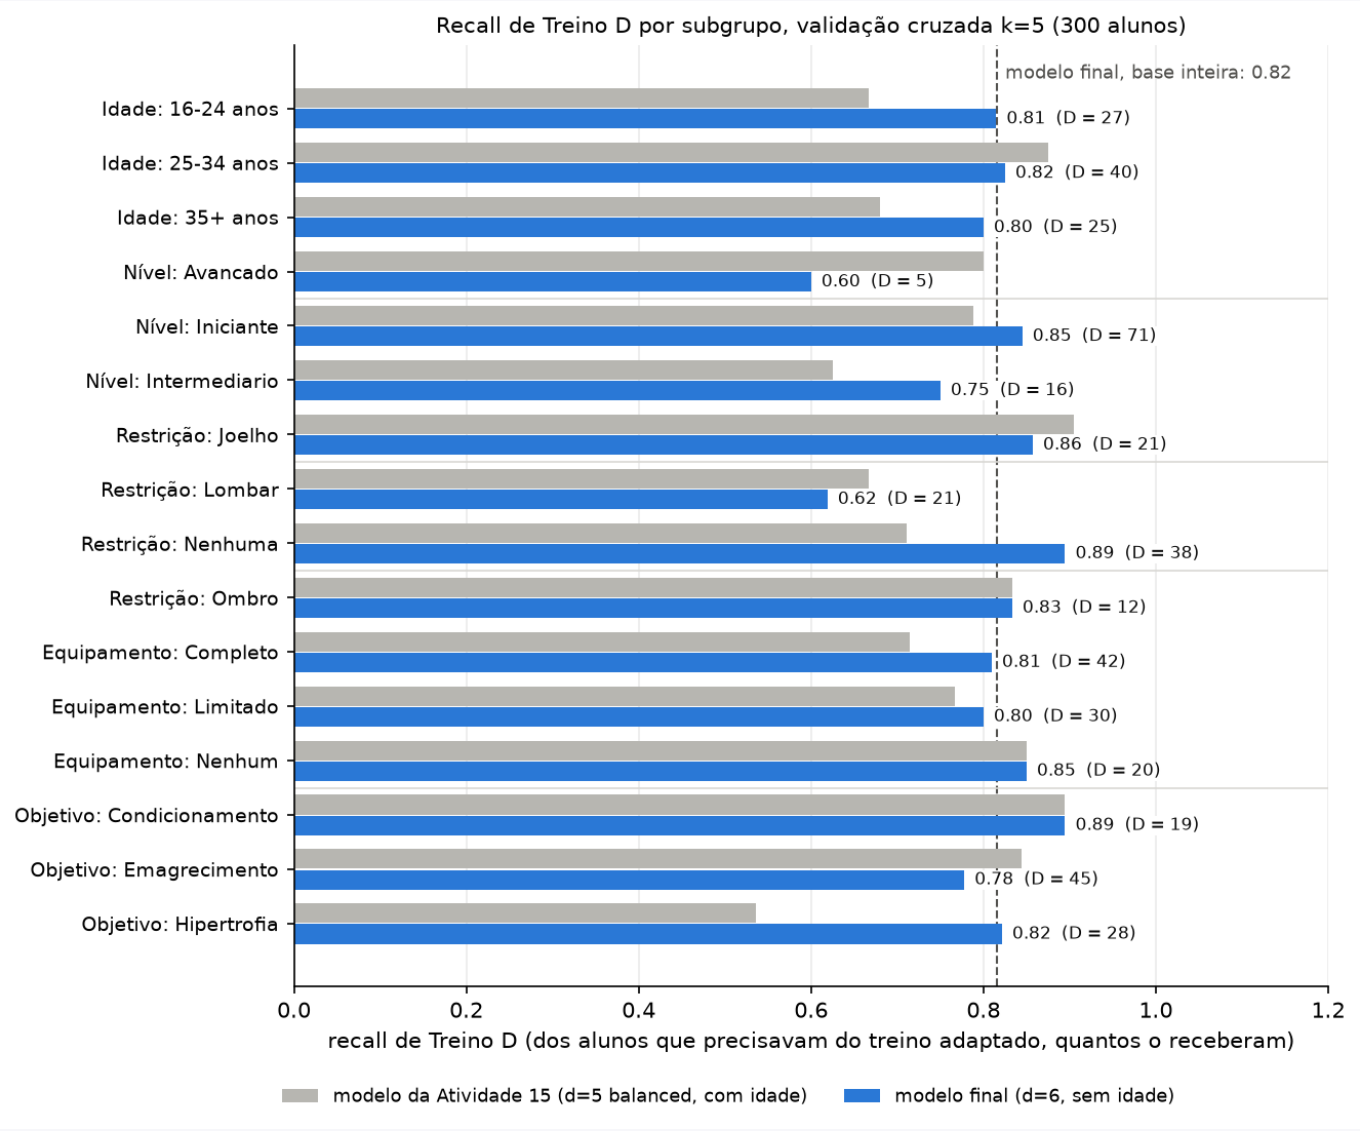
O que a árvore pergunta

As 6 features mais importantes são as **5 variáveis da regra real**.

Nenhum nó usa idade. Na AP2, "idade ≤ 19,5?" decidia entre A e D.

Auditoria de viés: o modelo erra igual para todos?

Critério 5 · recall de Treino D por subgrupo (validação cruzada, 300 alunos)



Melhorou

Idade: 0,67 / 0,88 / 0,68 → **0,82 / 0,83 / 0,80**

Hipertrofia: 0,54 → **0,82**

Continua ruim

Lombar: 0,62. Quem tem restrição e não é iniciante não cai na regra.

É um perfil com risco de lesão.

Quem não está na base

> 51 anos, gestantes, cardiopatas.

Restrição = **dado de saúde (LGPD)**. Equipamento = proxy de **renda**.

Riscos, limitações e próximos passos

Critério 5 · Análise crítica

Risco: Médio

Saúde, mas toda sugestão passa por um professor.

Vira **Alto** se usado sem revisão, como app direto ao aluno.

Uso indevido

Academia usa a saída como **prescrição automática** para poupar o professor, inclusive para quem tem 65 anos ou cardiopatia. O modelo nunca viu esses perfis e responde com a mesma "certeza".

Divulgar "90% de acerto". Usar "Treino D" para marcar aluno como "de risco" e encarecer o plano.

Limitação	Próximo passo
Base sintética: o modelo recupera a minha regra	Dados reais com consentimento, com a **decisão do professor** como rótulo
Pergunta mais fácil que a do Fitbod: só o 1º dia, sem saber se funcionou	Registrar a **aderência** nas primeiras 4 semanas
Lombar é o pior subgrupo (0,62)	Estender a regra a "lombar, qualquer nível" e medir quanto cresce a fila
Faltam variáveis: grau da restrição, liberação médica	Coletar e medir o recall de D dentro de Lombar antes e depois

Conclusão

O que o projeto faz: recupera a regra com 0,86 de acurácia (baseline 0,31) e, onde decide sozinho, entrega o treino adaptado a **83%** de quem precisa.

O que ele não faz: não foi validado com nenhum aluno real. Não está pronto para uso sem professor.

O que aprendi: a explicabilidade não serviu só para explicar. Foi ela que mostrou o erro da profundidade e as folhas perigosas.

Reprodutível: **AS_ViniciusCasagrande_ADS.ipynb** regera a base do zero e roda do início ao fim (Colab ou local, versões em requirements.txt).

Relatório final, registro de uso de IA e histórico das decisões no README.

Obrigado · github.com/Vinicasagrande87/fundamentos_ia