

Modelo Padrão de Entrega de Atividades

Atividade nº	5
Encontro	5 — 27/08/2026
Data	04/09/2026
Etapas	☒ Esboço ☐ Entrega final
Nome	Vinicius Casagrande
Domínio / tema do projeto	Academia — Recomendação de treinos e exercícios personalizados

O que foi feito nesta atividade

Nesta atividade a base do projeto (dataset_academia.csv, 300 registros simulados, a mesma da Atividade 4) foi investigada a fundo seguindo o roteiro da oficina: dimensões, dados ausentes, duplicados, inconsistências e desbalanceamento da variável de saída. A investigação foi executada no notebook atividade5_academia.ipynb (com saídas visíveis) e sintetizada no relatório curto de qualidade dos dados. Também foi produzida a primeira versão dos slides da AP1. A limpeza em si não é feita agora — será no Encontro 8 —, mas cada problema já tem ação de tratamento proposta e justificada.

Artefato verificável

Link do repositório	https://github.com/Vinicasagrande87/fundamentos_ia
Relatório de qualidade	relatorio_qualidade_dados.docx / .pdf (no repositório)
Notebook de investigação	atividade5_academia.ipynb — executado, com contagens de ausentes, duplicados, valores únicos, proporção de classes e gráfico do desbalanceamento (grafico_desbalanceamento.png)
Slides da AP1	slides_ap1.pdf / .pptx (no repositório) — versão preliminar

1. Diagnóstico dos problemas de qualidade

- Dimensões: 300 linhas × 8 colunas (aluno_id + 6 features + 1 variável de saída).
- Dados ausentes: 0 em todas as 8 colunas (0%). Resultado artificial da geração sintética — dados reais de alunos terão ausência, principalmente em restricao_fisica e objetivo.
- Dados duplicados: 0 linhas 100% idênticas; 0 registros repetidos pela chave aluno_id (1 a 300, sequencial). Há 7 repetições de perfil+rótulo ignorando o aluno_id (14 linhas) — colisões esperadas de um perfil de baixa cardinalidade, não erro de coleta.
- Inconsistências: (a) nivel_experiencia gravado sem acento ("Avancado", "Intermediario") divergindo do dicionário; (b) nivel_experiencia e equipamento_disponivel são ordinais mas estão como texto nominal; (c) dicionário diz idade "16–65", a base vai só até 51; (d) 24 registros (8,0%) têm rótulo que contradiz a regra de geração — ruído de 8% injetado de propósito, que impõe teto de acurácia de ~92%.
- Desbalanceamento da variável de saída treino_recomendado: Treino D 92 (30,7%), Treino C 80 (26,7%), Treino A 74 (24,7%), Treino B 54 (18,0%). Razão maior/menor = 1,7:1 — desbalanceamento leve.

Todas essas contagens estão no notebook, com as saídas visíveis.

2. Tabela de diagnóstico

Problema encontrado / onde	Grav.	Ação de tratamento proposta e justificativa	Quando
----------------------------	-------	---	--------

aparece			
Base 100% simulada — perfis e rótulos gerados por regra, não observados em alunos reais. Toda a base.	Alta	Substituir/complementar por dados reais (formulário + rótulo validado por profissional de educação física). Enquanto isso, tratar as métricas do modelo como prova de conceito. Escolhido em vez de "seguir só com a base simulada" porque a validade externa é o maior risco do projeto.	Ao obter dados reais (Encontro 8+)
Ausência de nulos é artificial. Todas as colunas (0/300).	Média	Construir o pipeline de ingestão prevendo nulos. Para nulos futuros: imputar restricao_fisica ausente como "Nenhuma" (mais provável e conservador) e sinalizar; descartar a linha só se faltar o objetivo. Preencher foi preferido a descartar porque a base é pequena.	Encontro 8
Ruído de rótulo de 8% — 24 registros com treino_recomendado que contradiz a regra de geração. treino_recomendado (24 linhas).	Média	Manter os 24 registros (exceções legítimas). Documentar teto de acurácia ~92% e não perseguir ajuste sobre eles. Alternativa descartada: removê-los — eliminaria a variabilidade que o modelo deve tolerar.	Encontro 9
Desbalanceamento leve — Treino B 18,0% vs Treino D 30,7% (1,7:1). treino_recomendado.	Média	class_weight="balanced" na Árvore, stratify no split e avaliação por F1-macro + matriz de confusão. Alternativa descartada: SMOTE/oversampling — desnecessário para desbalanceamento tão leve e arriscado com poucas linhas.	Encontro 8 e 9
nivel_experiencia sem acento ("Avançado", "Intermediário") divergindo do dicionário. Coluna nivel_experiencia.	Média	Vocabulário controlado + mapeamento de padronização na ingestão, para join consistente quando dados reais (acentuados) entrarem.	Encontro 8
Variáveis ordinais tratadas como texto nominal. nivel_experiencia e equipamento_disponivel.	Média	Codificação ordinal explícita (Iniciante<Intermediário<Avançado; Nenhum<Limitado<Completo), preservando a ordem que a Árvore usa nos cortes. Preferida a one-hot, que descartaria a ordem.	Encontro 8
Divergência dicionário × dado: idade documentada "16–65", base vai de 16 a 51. idade / dicionário do README.	Baixa	Corrigir o dicionário para a faixa real (16–51) agora; buscar cobertura de 50+ na coleta real.	Encontro 5 (doc) / coleta real
19 registros de menores (16–17) e apenas 2 com 50+. Coluna idade.	Baixa	Manter. Em dados reais, exigir consentimento do responsável para menores e monitorar desempenho por faixa etária.	Encontro 8/9
7 combinações perfil+rótulo repetidas (14 linhas), ignorando aluno_id. Base exceto aluno_id.	Baixa	Nenhuma remoção — colisões esperadas de perfil de baixa cardinalidade, não duplicata de coleta. Registrar o teste para reaplicar em dados reais.	Encontro 8 (se reaparecer)
Sub-representação: "sem equipamento" = 7,3% da base, e 20 de 22 desses casos têm rótulo fixo Treino D pela regra. equipamento_disponivel × treino_recomendado.	Média	Cota mínima para quem treina em casa na coleta real; enquanto isso, declarar que o modelo não personaliza bem para esse grupo e restringir o escopo de uso.	Coleta real / Encontro 8

3. Ações de tratamento propostas (resumo justificado)

As justificativas completas estão na coluna "Ação" da tabela acima e no relatório. Os pontos onde havia mais de uma opção:

- Ausentes (futuros) — preencher x remover: escolhido preencher restricao_fisica com "Nenhuma" (categoria majoritária, 69%, e a mais conservadora) e remover a linha apenas quando faltar o objetivo, porque a base é pequena e descartar linhas custa caro.
- Ruído de rótulo — manter x remover as 24 linhas: escolhido manter, porque são exatamente o tipo de exceção que o modelo precisa aprender a tolerar; removê-las deixaria o modelo otimista demais.
- Desbalanceamento — class_weight x oversampling/SMOTE: escolhido class_weight + stratify + F1-macro, porque 1,7:1 é leve e SMOTE em base pequena tende a criar exemplos artificiais ruins.
- Ordinais — codificação ordinal x one-hot: escolhida a ordinal, para não jogar fora a informação de ordem (Iniciante < Intermediário < Avançado) que a Árvore aproveita.

4. Discussão de possíveis vieses

Viés identificado: amostragem + rotulagem no grupo "sem acesso a equipamento".

- Quem está representado: aluno típico de academia paga — jovem adulto (média 29), iniciante, sem restrição física, com acesso a equipamento (92,7% da base).

- Quem ficou de fora: quem treina em casa sem equipamento (7,3%), pessoas 50+, quem tem mais de uma restrição física.
- Decisão humana do passado: o rótulo é a saída de uma regra escrita pelo estudante, não a avaliação de um educador físico — o modelo aprende essa opinião.
- Se o modelo errar, o prejudicado é o aluno iniciante ou com restrição física — no segundo caso, o erro pode significar risco de lesão.

Mitigação inicial: sobreamostrar os grupos sub-representados na coleta real, avaliar o modelo por subgrupo e documentar a limitação de forma visível. Detalhamento na versão final.

5. Slides preliminares da AP1

Primeira versão no repositório (slides_ap1.pdf / .pptx). Estrutura já montada seguindo o roteiro da AP1 (problema → tipo de problema e abordagem → base e dicionário → análise inicial e diagnóstico de qualidade → vieses → próximos passos). Alguns slides ainda serão refinados para a versão final.

Dificuldades e observações

A base é simulada e não tem ausentes, duplicatas reais nem erros de digitação — o risco era entregar um diagnóstico genérico. Para evitar isso, a investigação focou no que é de fato problemático nesta base: ser gerada por regra (rótulo sem validação profissional), o ruído de 8% (quantificado reproduzindo a regra de geração no notebook) e a sub-representação de grupos como "sem equipamento" e alunos mais velhos. O tratamento será executado no Encontro 8.

Declaração de uso de Inteligência Artificial

Uso de IA nesta entrega	☒ Sim ☐ Não
Ferramenta	Claude (Anthropic)
Utilização	Apoio na execução do notebook de investigação (código pandas para contagens de ausentes, duplicados, valores únicos e proporção de classes), na reprodução da regra de geração para quantificar o ruído de rótulo, e na redação e formatação deste documento, do relatório e dos slides a partir das decisões e da interpretação do estudante.
Produção própria	A definição de quais problemas importam para este projeto, a classificação de gravidade de cada um, a escolha entre alternativas de tratamento, a identificação e a análise do viés de acesso a equipamento e a leitura do que o diagnóstico significa para o projeto são do estudante. O conteúdo foi revisado e é de compreensão do estudante, que responde por ele na AP1.