

Limpeza e Preparação da Base — Atividade 8 (Entrega Final)

Recomendação de Treinos Personalizados em Academia

Atividade nº	8
Encontro	9
Etapa	Entrega final
Estudante	Vinicius do Canto Casagrande
Disciplina	Fundamentos de Inteligência Artificial — ADS/ULBRA

1. Notebook de preparação

O notebook está organizado em 8 seções com títulos em markdown (Carregamento, Recapitulação do diagnóstico, Transformações 3.1 a 3.7, Tabela de decisões, Comparação antes/depois, Verificação de vazamento, Salvamento e verificação, Prontidão para o Encontro 9), com código comentado e executado do início ao fim, sem erros, com todas as saídas visíveis. Arquivo: Atividade8_academia.ipynb (no repositório).

2. Transformações aplicadas

Sete transformações/decisões foram aplicadas, com base no diagnóstico de qualidade da Atividade 5:

Transformação	Coluna(s)	Estratégia escolhida vs. alternativa
Remover aluno_id das features	aluno_id	Manter só como índice, não como feature — evita vazamento indireto (posição do registro)
Padronizar nomenclatura (strip + title case)	5 colunas categóricas	Padronização sintática, sem alternativa necessária
Converter ordinais para categoria ordenada	nivel_experiencia, equipamento_disponivel	Registrar ordem nos dados, não deixar para a modelagem (evita erro de interpretação)
Confirmar ausência de nulos/duplicados	todas	Verificação, sem alternativa aplicável
Atualizar dicionário de dados (faixa etária)	idade (documentação)	Corrigir a documentação, não os dados — rejeitada a opção de forçar dados para bater com o dicionário antigo
Manter ruído de rótulo (8%) sem correção	treino_recomendado	Sem critério confiável para distinguir ruído de exceção legítima — rejeitada a remoção arbitrária
Não tratar desbalanceamento nesta etapa	treino_recomendado	É decisão de modelagem (stratify no split), não de limpeza

3. Registro completo das decisões

A tabela de decisões completa (transformação · coluna afetada · motivo · impacto em linhas/colunas · risco associado) está no notebook, seção 4. Resumo do impacto agregado:

Linhas antes	300
Linhas depois	300 (nenhuma removida)
Colunas antes	8 (incluindo aluno_id como coluna)
Colunas depois	7 features + label (aluno_id preservado apenas como índice)

4. Base tratada — salva e verificada

Arquivo `dataset_academia_tratado.csv` salvo no repositório. Verificação feita por releitura do arquivo salvo dentro do próprio notebook (seção 7), confirmando shape (300 linhas × 8 colunas) e tipos após a releitura. O arquivo original `dataset_academia.csv` permanece intacto e sem nenhuma alteração — todas as transformações foram aplicadas sobre uma cópia (`df = df_original.copy()`).

5. Verificação de vazamento — concluída

Transformações que aprendem parâmetros sobre a base inteira antes do split:

Nenhuma. As transformações aplicadas nesta etapa (remoção de coluna, padronização de texto, conversão de tipo) são determinísticas e não aprendem nenhuma estatística dos dados — não há normalização, imputação por média/mediana nem encoding que aprenda frequências. A codificação numérica das categorias (que precisaria de fit só no treino) fica para o Encontro 9, após o split.

Identificadores removidos das features:

Sim — `aluno_id` foi movido para índice do DataFrame e não integra as colunas de entrada do modelo.

Colunas pós-desfecho entre as entradas:

Nenhuma. As 6 features descrevem o perfil do aluno antes de qualquer treino ser recomendado; `treino_recomendado` é o label, não uma feature.

6. Prontidão para o Encontro 9

Já pronto:

Base sem identificador entre as features, nomenclatura padronizada, variáveis ordinais tipadas corretamente, sem vazamento identificado, salva e verificada.

Ainda falta:

Codificação numérica das variáveis categóricas (deixada para depois do split, para evitar vazamento) e a divisão treino/teste em si (80/20 estratificada, já planejada na Atividade 7) — ambas a serem feitas no início do Encontro 9, imediatamente antes do treinamento do primeiro modelo.

7. Backlog da AP2 (atualizado)

Tarefa	Status	Quando
Coleta / geração da base de dados	Concluído	Já feito
Limpeza e preparação da base (nomenclatura, tipos, remoção de <code>aluno_id</code>)	Concluído	Já feito (Atividade 8)
Divisão treino/teste com stratify (80/20)	A fazer	Encontro 9
Codificação numérica das categorias (fit apenas no treino)	A fazer	Encontro 9
Treinamento do primeiro modelo — Árvore de Decisão	A fazer	Encontro 9
Validação cruzada (k=5) para ajuste de hiperparâmetros	A fazer	Encontro 9
Avaliação no conjunto de teste (F1-macro, matriz de confusão, desempenho por subgrupo)	A fazer	Encontro 10
Interpretação dos resultados, considerando a limitação da base simulada	A fazer	Encontro 10
Preparar apresentação final do projeto	A fazer	Encontro 11 (AP2)

8. Organização, dificuldades e observações

Esta atividade não teve uma etapa de esboço separada entregue anteriormente — esboço e entrega final estão sendo consolidados nesta única entrega. A principal dificuldade técnica foi decidir o que tratar como "limpeza" e o que deixar como "decisão de modelagem": o ruído de rótulo e o desbalanceamento poderiam ser "corrigidos" aqui, mas isso arriscaria distorcer os dados sem critério confiável — por isso ambos foram documentados como decisões conscientes de não tratamento nesta etapa, e não como pendências esquecidas.

Declaração de uso de Inteligência Artificial

Uso de IA nesta entrega: Sim

Ferramenta: Claude (Anthropic)

Utilização:

Apoio na reconstrução do script gerador da base (a partir da metodologia já documentada no README, já que o arquivo original não estava disponível no momento desta entrega), na estruturação e no código do notebook de limpeza, e na redação deste documento.

Produção própria:

A decisão de quais transformações aplicar (e quais não aplicar, como o ruído de rótulo e o desbalanceamento), a justificativa de cada uma frente a estratégias alternativas, a conclusão da verificação de vazamento e a definição do backlog atualizado são de minha autoria, com base no diagnóstico de qualidade da Atividade 5.