MODELO PADRÃO DE ENTREGA DE ATIVIDADES

Etapa	Entrega final	**Atividade**	11
Encontro	11	**Curso**	ADS / ULBRA
Aluno	Vinicius Casagrande	**Professor(a)**	Caroline Pacheco da Rosa
Projeto	Recomendação de treinos personalizados em academia		

Artefato verificável

Repositório (GitHub): https://github.com/Vinicasagrande87/fundamentos_ia

Notebook fonte da análise: atividade10_academia.ipynb (seções 13 a 15 — validação cruzada, teste de class_weight='balanced' e comparação das regras da árvore com a regra de geração).

Backlog da AS: entregas/Backlog_AS_ViniciusCasagrande.md

README.md atualizado: seção "11. Atividade 11 — Revisão técnica da AP2".

Contexto

Esta é uma revisão técnica do modelo apresentado na AP2 (Árvore de Decisão, max_depth=5, treinada para recomendar a categoria de treino — A, B, C ou D — de um aluno de academia). A AP2 obteve 1,5 de 2,5 pontos. O foco aqui não é a ideia do projeto, é o comportamento técnico do modelo: o que funcionou, o que não funcionou, por que, e o que muda até o Encontro 17 (AS).

1. O que funcionou bem no modelo

1.1 O modelo superou o baseline com margem clara e sem overfitting

O que funcionou: a Árvore de Decisão atingiu 0,90 de acurácia no teste contra 0,30 do baseline (DummyClassifier, most_frequent) — diferença de +0,60. O teste de treino vs. teste (seção 7 do notebook) mostrou acurácia de treino de 0,8875 contra 0,90 no teste — uma diferença de apenas -0,0125, com o teste levemente acima do treino.

Por que considero um acerto: a diferença mínima (e invertida) entre treino e teste é evidência concreta de que o modelo não decorou os dados de treino. Com max_depth=5 limitando a complexidade, a árvore generalizou em vez de memorizar — mesmo havendo 8% de ruído de rótulo proposital na base (Atividade 9) que poderia ter sido memorizado por um modelo mais profundo.

Como será preservado: a profundidade máxima (5) é mantida como configuração padrão daqui pra frente; qualquer teste de modelo mais complexo (ex.: Random Forest, árvore mais profunda) passará pelo mesmo teste treino-vs-teste antes de ser adotado.

1.2 class_weight='balanced' melhorou o ponto mais fraco do modelo sem custo aparente

O que funcionou: testamos `DecisionTreeClassifier(max_depth=5, random_state=42, class_weight='balanced')` contra o modelo original (seção 14 do notebook). O recall da classe Treino D — a métrica principal do projeto, pelo custo do erro — subiu de 0,7778 para 0,8333. A acurácia geral subiu junto, de 0,90 para 0,9167. Nenhuma outra classe piorou: Treino B e Treino C ficaram idênticos, e a precisão de Treino A até melhorou (0,7895 → 0,8333).

Por que considero um acerto: encontrar uma mudança de configuração que melhora exatamente a métrica mais importante do projeto (recall de Treino D, ligado ao risco de recomendar um treino mais intenso do que o indicado), sem piorar nada mais, é um resultado raro e vale a pena registrar com evidência numérica, não só "parece melhor".

Como será preservado: `class_weight='balanced'` será promovido a configuração padrão do modelo (ver item 4.1 — ainda não foi aplicado nas seções 1 a 11 do notebook, só testado e comparado na seção 14).

2. O que não funcionou

2.1 A validação cruzada revelou que o resultado de 0,90 não é confiável como número único

O que não funcionou: a validação cruzada k=5 (seção 13 do notebook) deu acurácia média de 0,8267 com desvio padrão de 0,0291 — bem abaixo dos 0,90 do split único usado em todo o resto da avaliação. O fold mais fraco ficou em 0,7833, mais de 10 pontos percentuais abaixo do número reportado nos slides da AP2.

Consequência prática: todos os números que apresentei na AP2 (0,90 de acurácia, 0,7778 de recall de Treino D) vêm de UM split específico (random_state=42), que — como a validação cruzada mostrou — foi relativamente favorável. Quem decidir se o modelo "está pronto" com base só no 0,90 está sendo enganado por sorte de amostragem, não por desempenho real.

O quanto compromete: é uma falha de comunicação, não de modelo — o modelo em si não mudou, mas a forma como reportei o resultado na AP2 superestimou a confiança que se deve ter nele. Compromete a credibilidade da apresentação se a defesa não deixar isso claro.

2.2 A árvore erra usando um atalho espúrio (idade) exatamente nos perfis de maior risco

O que não funcionou: dos 4 falsos negativos de Treino D no conjunto de teste (seção 15 do notebook), nenhum tem equipamento "Nenhum" — a condição mais óbvia da regra real (`recomenda_treino`, em gerar_dataset.py). São todos casos mais sutis. Comparando o `export_text` da árvore com a regra de geração, em pelo menos dois desses quatro casos (idade 41 e idade 16) a árvore aprendeu a decidir usando IDADE numa região em que a regra real depende de nível de experiência ou de dias disponíveis — uma correlação que funciona parcialmente no treino, mas não é a regra verdadeira do domínio.

Consequência prática: para um aluno real com um perfil parecido com esses quatro (sem a condição óbvia do "sem equipamento", mas ainda assim um caso para Treino D), o modelo tem uma chance concreta de recomendar algo mais intenso do que deveria — exatamente o erro mais caro identificado na seção 5 do notebook.

O quanto compromete: é o problema técnico mais sério do projeto hoje, porque não é um erro aleatório — é um padrão sistemático e documentado de onde o modelo falha, e justamente nos perfis que a seção 6 já tinha identificado como mais importantes.

3. Possíveis causas dos erros

3.1 Causa da instabilidade entre split único e validação cruzada

Hipótese (sustentada por evidência): a base tem só 300 registros, com 60 no conjunto de teste de cada split. Com um teste tão pequeno, a composição exata de quais alunos caem no teste muda bastante a acurácia observada — é a definição de "base pequena demais para confiar num único split". O `random_state=42` usado desde a Atividade 9 gerou, por acaso, um teste relativamente fácil; os 5 folds da validação cruzada, cobrindo toda a base, dão uma estimativa mais honesta (~0,83).

Pergunta da professora sobre isso (registrada aqui para a defesa): se a base tivesse 3.000 registros em vez de 300, o desvio padrão entre folds tenderia a cair — o erro padrão de uma média cai aproximadamente na proporção de 1 sobre a raiz quadrada do tamanho da amostra, então 10x mais dados tenderiam a reduzir o desvio de ~0,029 para algo da ordem de ~0,009. Isso reforça que a instabilidade observada é sintoma de base pequena, não de o modelo ser ruim — e que a média da validação cruzada (~0,83) é uma estimativa mais confiável do que qualquer número de split único, exatamente por isso.

3.2 Causa do atalho espúrio por idade

Hipótese (sustentada por evidência): a base tem ~8% de ruído de rótulo proposital (Atividade 9, seção 8). Com profundidade limitada a 5 e dados ruidosos, a árvore precisa escolher, em cada divisão, a variável que melhor separa os exemplos que viu no treino — inclusive os exemplos ruidosos. Nos casos mais difíceis (perfis fronteiriços de Treino D), parece que idade acabou sendo, por coincidência estatística no conjunto de treino, uma variável que

separava bem os exemplos vistos, mesmo não sendo a variável causal real (nível de experiência / dias disponíveis). Isso é uma espécie de sobreajuste localizado: não aparece no teste global de overfitting (seção 7), porque é um problema concentrado numa região pequena da árvore, não no modelo inteiro.

Pergunta da professora sobre isso (registrada aqui para a defesa): o `class_weight='balanced'` melhorou tanto o recall de Treino D quanto a acurácia geral no split de teste usado — um resultado incomum, já que balancear classes normalmente troca acurácia geral por recall nas classes minoritárias. Eu esperaria que balancear piorasse a acurácia geral numa situação em que a classe majoritária já é difícil de acertar e perde peso relativo — aí os erros novos na maioria pesariam mais do que os ganhos nas minorias. Também esperaria que o resultado fosse menos consistente em outro split: como a melhora foi avaliada só no split único (random_state=42), e a seção 2.1 já mostrou que esse split é relativamente favorável, a melhora do balanced pode não se repetir da mesma forma nos 5 folds da validação cruzada — isso ainda não foi testado (ver item 4.1) e é a verificação mais importante antes de assumir que o balanceamento é uma melhoria garantida.

4. Melhorias definidas para a etapa final

4.1 Validar class_weight='balanced' com validação cruzada, não só no split único

Ação concreta: repetir a validação cruzada k=5 (mesma seção 13) agora com `class_weight='balanced'` e comparar a média e o desvio padrão com os 0,8267 ± 0,0291 do modelo original.

Por que deve resolver: hoje a melhora do balanced só foi medida num split possivelmente favorável (seção 2.1); rodar com validação cruzada mostra se o ganho é real e estável ou um artefato desse split específico.

Quando: Encontro 12.

4.2 Promover class_weight='balanced' a configuração padrão (se confirmado no item 4.1)

Ação concreta: se a validação cruzada confirmar a melhora, substituir o `DecisionTreeClassifier` original pela versão com `class_weight='balanced'` nas seções 1 a 11 do notebook, e reexecutar toda a avaliação (matriz de confusão, métricas por classe, comparação com baseline) com essa configuração.

Por que deve resolver: hoje o ajuste está isolado na seção 14, como teste — não é o modelo que de fato está sendo avaliado no resto do notebook. Promovê-lo unifica a análise em cima da melhor configuração conhecida.

Quando: Encontro 12-13.

4.3 Investigar o atalho por idade com profundidade maior e comparação com Random Forest

Ação concreta: treinar uma árvore com profundidade maior (ex.: max_depth=7) e também o Random Forest já citado no backlog anterior, comparar a importância de features (`feature_importances_`) de cada um com a árvore atual, e ver se idade continua aparecendo como critério de decisão nos perfis-fronteira identificados na seção 15.

Por que deve resolver: se o atalho por idade desaparecer com mais profundidade ou num modelo em conjunto, isso confirma que era um efeito de capacidade limitada; se persistir, é sinal de que a base/features realmente carecem de algo (ex.: uma variável que combine experiência e dias disponíveis de forma mais direta).

Quando: Encontro 13-14.

4.4 Reportar validação cruzada como o número de referência, não o split único

Ação concreta: atualizar os slides e qualquer relatório futuro para apresentar "~0,83 (validação cruzada, desvio 0,03)" como o número principal, com o 0,90 do split único citado apenas como contexto histórico da Atividade 9.

Por que deve resolver: evita repetir, na AS, o mesmo problema de comunicação identificado no item 2.1.

Quando: Encontro 12, antes de qualquer nova apresentação.

5. Backlog da AS atualizado

Backlog completo com status em entregas/Backlog_AS_ViniciusCasagrande.md. Resumo abaixo.

- [Concluído] Validação cruzada k=5 do modelo original — média 0,8267, desvio 0,0291 (Atividade 10)
- [Concluído] Teste de class_weight='balanced' no split único — recall de Treino D 0,78→0,83 (Atividade 10)
- [Concluído] Comparação das regras da árvore com a regra de geração — atalho por idade identificado (Atividade 10)
- [A fazer] Validação cruzada com class_weight='balanced' (item 4.1) — Encontro 12
- [A fazer] Promover class_weight='balanced' a configuração padrão, se confirmado (item 4.2) — Encontro 12-13
- [A fazer] Testar profundidade maior e Random Forest, comparar feature_importances_ (item 4.3) — Encontro 13-14
- [A fazer] Atualizar slides/relatórios para reportar validação cruzada como número de referência (item 4.4) — Encontro 12
- [A fazer] Notebook final executável de ponta a ponta, com a configuração definitiva do modelo — Encontro 15
- [A fazer] README completo com instruções de execução atualizadas — Encontro 15
- [A fazer] Relatório final do projeto — Encontro 16
- [A fazer] Análise ética e crítica do projeto (viés de equipamento já identificado na Atividade 5, base sintética vs. real) — Encontro 16
- [A fazer] Evidências de execução (notebook exportado com saídas, prints/capturas) organizadas no repositório — Encontro 16
- [A fazer] Registro final de limitações e melhorias futuras, consolidando esta revisão técnica — Encontro 17

Organização, dificuldades e observações

A principal dificuldade desta revisão foi separar "o que o modelo faz" de "como eu comuniquei o que o modelo faz" — o maior problema encontrado (seção 2.1) não é um defeito do modelo em si, é que a forma como reportei o resultado (um único split) escondeu a instabilidade real que só a validação cruzada revelou. A segunda dificuldade foi usar o `export_text` da árvore e os perfis dos falsos negativos para formular uma hipótese de causa verificável (o atalho por idade), em vez de apenas dizer "o recall está baixo" sem explicar por quê — essa investigação (seção 15 do notebook) foi o que tornou possível a melhoria concreta descrita no item 4.3, em vez de uma ação vaga como "melhorar o modelo".

Declaração de uso de Inteligência Artificial

Uso de IA: Sim

Ferramentas utilizadas: ChatGPT e Claude (Anthropic) / IA generativa

Como foi usada:

- apoio na estruturação do código das investigações do notebook (validação cruzada, class_weight='balanced', comparação de export_text com os perfis dos falsos negativos) e na organização do repositório;
- apoio na redação deste documento de revisão técnica, incluindo a formulação das hipóteses de causa a partir dos números já calculados no notebook;
- revisão ortográfica e de organização das seções desta entrega.

Produção própria:

a identificação de quais pontos registrar como "funcionou" e "não funcionou" a partir da própria experiência com o modelo e com a apresentação da AP2; a interpretação de que o problema central é a diferença entre o split único e a validação cruzada, e não um defeito do modelo; a formulação das respostas às duas perguntas feitas pela professora no feedback da Atividade 10 (sobre quando o balanceamento de classes pioraria o resultado, e sobre o efeito do

tamanho da base no desvio padrão da validação cruzada); a definição das ações concretas de melhoria e dos prazos no backlog da AS; e a análise de que o atalho por idade identificado na árvore é consistente com o ruído de rótulo da base, foram realizadas pelo aluno, com adaptação ao caso real do projeto.