MODELO PADRÃO DE ENTREGA DE ATIVIDADES

Etapa	Entrega final	**Atividade**	14
Encontro	14	**Curso**	ADS / ULBRA
Aluno	Vinicius Casagrande	**Professor(a)**	Caroline Pacheco da Rosa
Projeto	Recomendação de treinos personalizados em academia		

Artefato verificável

Repositório (GitHub): https://github.com/Vinicasagrande87/fundamentos_ia

README.md atualizado: seção "14. Atividade 14 — Análise técnica de uma aplicação real de IA".

1. Aplicação escolhida e contexto

Aplicação: Fitbod — aplicativo de treinos de musculação personalizados, desenvolvido pela Fitbod, Inc. (EUA).

https://fitbod.me

O Fitbod é um aplicativo de celular que monta, sessão a sessão, um treino de musculação personalizado para o usuário: lista de exercícios, séries, repetições e carga. Ele é voltado a praticantes de musculação de qualquer nível — de iniciantes a avançados — que treinam sozinhos (sem personal trainer) e querem um plano que se adapta ao que já foi treinado, ao equipamento disponível no momento e à recuperação muscular estimada. É um concorrente direto do domínio do meu projeto: já era citado na minha AP1 como solução semelhante à que eu propus construir.

2. Dados de entrada

Com base na documentação pública da própria Fitbod e em análises de terceiros, o aplicativo usa:

- Histórico de treino logado pelo usuário: quais exercícios, séries, repetições e cargas foram feitos em cada sessão anterior.
- RiR ("reps in reserve", repetições que sobrariam até a falha) informado pelo usuário ao final de cada série — um dado subjetivo de esforço percebido que o app usa para decidir se a próxima sessão deve carregar mais ou menos peso.
- Objetivo do usuário (ex.: hipertrofia, força) e equipamento disponível no momento (selecionado explicitamente antes de cada sessão).
- Recuperação muscular estimada — calculada pelo próprio app a partir do tempo decorrido e do volume treinado por grupo muscular nas sessões anteriores, não informada diretamente pelo usuário.
- Feedback explícito sobre exercícios (marcar como favorito, evitar, ou excluir um exercício), que passa a influenciar as recomendações seguintes.
- Opcionalmente, dados de wearables (Apple Health, Health Connect, Fitbit, Strava).

Alguns desses dados são fornecidos de forma consciente pelo usuário (objetivo, equipamento, RiR, feedback sobre exercícios) e outros são calculados implicitamente pelo sistema a partir do histórico (recuperação muscular estimada, frequência por grupo muscular). A empresa também afirma usar dados agregados de mais de 400 milhões de treinos logados por toda a base de usuários para calibrar o algoritmo — isso não é um dado de entrada da sessão de um usuário específico, mas influencia o comportamento geral do sistema.

3. Saída produzida

A saída de cada sessão é um treino estruturado e prescritivo: uma lista ordenada de exercícios, com número de séries, repetições e peso-alvo sugerido para cada série. Na sessão seguinte, a carga sugerida é ajustada a partir do

RiR logado na sessão anterior — se o usuário relatou folga demais (RiR alto), o app tende a sugerir mais carga; se relatou estar perto da falha (RiR baixo), tende a manter ou reduzir.

A saída é apresentada como uma prescrição direta — "faça 4 séries de 8 a 10 repetições com X kg" — sem nenhum indicador visível de confiança ou de alternativas. O usuário não vê "o sistema está 70% confiante nessa carga"; ele vê um número só, apresentado como se fosse a recomendação correta, não uma estimativa.

4. Técnica provável, com justificativa

A entrada é majoritariamente histórico estruturado de comportamento do próprio usuário (séries, cargas, RiR) combinado com filtros explícitos (equipamento disponível) e a saída é uma estrutura numérica prescritiva (séries, repetições, peso) — não uma categoria única nem um conteúdo gerado livremente. Pela tabela de apoio da atividade, isso se aproxima mais de um sistema de recomendação/regra do que de visão computacional, PLN ou um modelo generativo.

Uma análise técnica de terceiros (independente da Fitbod) descreve a lógica da sessão como: um escore de "frescor" por grupo muscular calculado a partir do histórico, um filtro por equipamento disponível, e uma sequência de séries/cargas definida a partir do histórico logado — ou seja, um sistema de regras auditável (score + filtro + ajuste incremental por RiR) por trás da experiência imediata do usuário. A própria Fitbod, em material de marketing, fala em "machine learning sobre o comportamento do usuário" e em usar os 400 milhões de treinos agregados da base toda — o que sugere que algum componente estatístico/ML provavelmente ajusta parâmetros gerais do sistema (ex.: quanto aumentar a carga dado um certo RiR, em média, pela base inteira), mesmo que a decisão por sessão, individualmente, pareça seguir regras determinísticas e auditáveis.

Minha conclusão, com a incerteza que a própria atividade prevê (a empresa não publica a arquitetura): o Fitbod provavelmente é um sistema híbrido — um núcleo de regras explícitas e auditáveis (filtro por equipamento, escore de recuperação, ajuste por RiR) calibrado por aprendizado sobre dados agregados de comportamento, não um classificador ou rede neural única decidindo a prescrição ponta a ponta. Isso é coerente com a última linha da tabela de apoio da atividade ("decide com base em regras fixas e auditáveis" pode não ser aprendizado de máquina no sentido estrito) combinada com a linha de sistemas de recomendação.

5. Riscos, limitações e impactos

Custo assimétrico do erro:

O erro mais custoso é sugerir carga ou volume acima do que o corpo do usuário suporta naquele momento (recuperação insuficiente, ou um RiR mal reportado) — resultando em risco real de lesão. O erro oposto, sugerir carga abaixo do que o usuário suportaria, só custa eficiência: o treino fica sub-aproveitado, mas sem risco. Essa é exatamente a mesma assimetria de custo que identifiquei no meu próprio projeto entre recomendar um treino mais intenso do que o indicado (falso negativo de Treino D) e recomendar um treino mais conservador do que o necessário (falso positivo de Treino D).

Quem é prejudicado:

Principalmente o próprio usuário, na forma de risco de lesão ou de treino inadequado. Usuários novos ou que treinam com pouca regularidade são mais prejudicados: uma revisão independente aponta que o algoritmo do Fitbod precisa de 10 a 15 treinos logados antes de a personalização atingir qualidade plena — ou seja, exatamente os usuários que mais precisariam de orientação cuidadosa (iniciantes) são os que recebem as recomendações menos confiáveis no início.

Risco de viés:

O sistema é calibrado sobre dados agregados de mais de 400 milhões de treinos logados pela base de usuários do próprio app. Essa base tende a ser composta por pessoas que já usam aplicativos de treino — provavelmente mais jovens, mais familiarizadas com tecnologia, e sem certas limitações físicas. Grupos sub-representados nesse agregado (pessoas mais velhas, com restrições físicas, iniciantes absolutos, ou que não logam consistentemente) correm o risco de receber recomendações calibradas para um perfil que não é o delas — um paralelo direto com o viés de acesso a equipamento que identifiquei na minha própria base sintética (Atividade 5).

Explicabilidade:

A recomendação é apresentada como um número direto, sem nenhuma explicação visível do porquê daquela carga ou daquele exercício específico — mesmo que, por trás, exista uma lógica de regras relativamente simples (frescor muscular, equipamento, RiR). Para quem usa o app, o sistema se comporta como caixa-preta, mesmo que tecnicamente não seja uma rede neural opaca.

Dependência excessiva:

Como o RiR é autorreportado e subjetivo, erros sistemáticos de autoavaliação (usuários que subestimam ou superestimam o próprio esforço) se acumulam ao longo do tempo, porque cada sessão se baseia na anterior. Um usuário que confia cegamente na prescrição, sem desenvolver a própria percepção de esforço, fica vulnerável a esse efeito cumulativo sem perceber.

6. Conexão com o meu projeto

O que a aplicação faz que o meu projeto também tenta fazer, em escala muito menor: personalizar uma recomendação de treino a partir do perfil e das condições do usuário. A diferença principal é de granularidade e de dinâmica — o Fitbod decide sessão a sessão, com dados que mudam a cada treino logado; o meu projeto decide uma categoria (Treino A, B, C ou D) uma única vez, a partir de um perfil estático (idade, objetivo, experiência, dias disponíveis, restrição física, equipamento).

Decisão técnica que eu poderia aproveitar: o Fitbod aplica o filtro de equipamento disponível como uma regra dura, antes de qualquer pontuação ou recomendação — não deixa isso a cargo só do modelo estatístico. No meu projeto, a regra de geração da base (`gerar_dataset.py`) também trata "sem equipamento" como condição que força Treino D, mas a árvore treinada (Atividade 10, seção 15) nem sempre aprendeu essa regra com perfeição — em alguns casos ela usa idade como atalho em vez do equipamento. Uma melhoria concreta seria envolver o modelo com uma camada de regra explícita e auditável (se equipamento == Nenhum, forçar Treino D), em vez de confiar inteiramente no que a árvore aprendeu sozinha — exatamente o padrão híbrido regra+aprendizado que identifiquei no Fitbod.

Limitação compartilhada: os dois sistemas dependem de dados que não representam toda a população de usuários possíveis — o Fitbod por um viés de quem já usa apps de treino e loga com regularidade; o meu projeto por usar uma base inteiramente sintética, nunca validada com alunos reais de academia (limitação já registrada desde a Atividade 9).

Erro que eu quero evitar: a falta de explicabilidade visível ao usuário final. O Fitbod entrega um número sem justificativa; no meu projeto, escolhi deliberadamente uma Árvore de Decisão (em vez de um modelo de caixa-preta) exatamente para poder mostrar a regra por trás da recomendação (`export_text`, Atividade 9) — e pretendo manter essa prioridade de explicabilidade mesmo se, na AS, eu adotar um modelo mais complexo (ex.: a rede neural MLP comparada na Atividade 13), reportando sempre a razão da recomendação, não só o resultado.

Organização, dificuldades e observações

A principal dificuldade foi diferenciar o que a Fitbod divulga como marketing ("machine learning", "IA") do que análises técnicas independentes realmente descrevem sobre o funcionamento do sistema — a empresa não publica a arquitetura, então foi preciso cruzar várias fontes (documentação oficial de ajuda, blog da empresa e uma revisão técnica de terceiros) para chegar a uma hipótese específica (sistema híbrido de regras auditáveis + ajuste estatístico sobre dados agregados) em vez de aceitar a afirmação genérica de "usa IA" sem examinar o que isso quer dizer na prática.

Declaração de uso de Inteligência Artificial

Uso de IA: Sim

Ferramentas utilizadas: Claude (Anthropic) / IA generativa, com busca na web para levantamento de fontes sobre o funcionamento do Fitbod

Como foi usada:

- apoio na busca e síntese de fontes públicas (documentação de ajuda da Fitbod, blog da empresa e uma revisão técnica de terceiros) sobre as entradas, saídas e o funcionamento provável do algoritmo;
- apoio na organização e redação deste documento segundo as seções exigidas pelo modelo padrão;
- revisão ortográfica e de clareza do texto.

Produção própria:

a escolha do Fitbod como aplicação a analisar (por já ter sido citado como referência de domínio na minha AP1); a leitura crítica de que o sistema é provavelmente híbrido (regras auditáveis + ajuste estatístico agregado), cruzando o marketing da empresa com uma fonte técnica independente, em vez de aceitar a descrição oficial sem checagem; a identificação da assimetria de custo entre sugerir carga demais ou de menos, e sua conexão direta com a mesma assimetria já identificada no meu próprio projeto (recall de Treino D); a análise de viés ligada à base de 400 milhões de treinos agregados e o paralelo com o viés de equipamento da minha própria base; e a conexão concreta com o meu projeto — a sugestão de usar uma regra explícita de equipamento como camada auxiliar ao modelo, e o compromisso de manter a explicabilidade mesmo ao evoluir para modelos mais complexos — foram realizadas pelo aluno, com adaptação ao caso real do projeto.