

Relatório de qualidade dos dados

Projeto: Recomendação de treinos personalizados em academia · Atividade 5 — Encontro 5
Vinicius Casagrande · Fundamentos de Inteligência Artificial — ADS/ULBRA · 03/09/2026

1. Base analisada e dimensões

Base: `dataset_academia.csv`, a mesma versão simulada documentada na Atividade 4 (300 registros, gerada em Python com seed fixa 1053). A investigação abaixo foi executada no notebook `atividade5_academia.ipynb`, com todas as saídas visíveis.

- Dimensões: 300 linhas (alunos) × 8 colunas.
- Colunas: `aluno_id` (identificador), 6 features de entrada (`idade`, `objetivo`, `nivel_experiencia`, `dias_disponiveis_semana`, `restricao_fisica`, `equipamento_disponivel`) e 1 variável de saída (`treino_recomendado`).
- Tipos: `idade` e `dias_disponiveis_semana` como inteiros; as demais como texto.

2. Diagnóstico dos problemas de qualidade

2.1 Dados ausentes

Nenhum valor ausente em nenhuma das 8 colunas (0 de 2.400 células; 0%). Este resultado NÃO é uma qualidade real da base — é um artefato da geração sintética. Quando dados reais de alunos entrarem (formulário, planilha da recepção), é esperado haver ausência principalmente em `restricao_fisica`, `objetivo` e `equipamento_disponivel`. O pipeline de ingestão já precisa prever esse caso.

2.2 Dados duplicados

- Linhas 100% idênticas: 0.
- Registros repetidos pela chave `aluno_id`: 0 — a chave vai de 1 a 300, sequencial e única.
- Linhas com o mesmo perfil e o mesmo rótulo, ignorando `aluno_id`: 7 repetições (14 linhas envolvidas). Com apenas 6 atributos de baixa cardinalidade, colisões de perfil são estatisticamente esperadas e não indicam erro de coleta — dois alunos diferentes podem realmente ter o mesmo perfil resumido. Não serão removidas.

2.3 Inconsistências

- Acentuação: `nivel_experiencia` está gravado sem acento ("Avancado", "Intermediario"), enquanto o dicionário de dados do README usa "Avançado"/"Intermediário". Divergência dicionário × base — risco de join inconsistente quando dados reais (acentuados) forem integrados.
- Tipos ordinais como texto nominal: `nivel_experiencia` (Iniciante < Intermediário < Avançado) e `equipamento_disponivel` (Nenhum < Limitado < Completo) têm ordem natural, mas estão como texto simples — a informação de ordem se perde se não houver codificação ordinal na preparação.
- Divergência doc × dado: o dicionário documenta `idade` "16 a 65"; a base real vai apenas até 51.
- Ruído de rótulo: reproduzindo a regra de associação que gerou a base, 24 registros (8,0%) têm `treino_recomendado` que NÃO segue a regra — é o ruído de 8% injetado de propósito na Atividade 4. Consequência: o classificador tem teto de acurácia de ~92% nesta base.

- Não há grafias divergentes dentro de cada coluna nem unidades misturadas (efeito da geração sintética) — registrado por honestidade.

2.4 Desbalanceamento da variável de saída

Proporção de cada classe em treino_recomendado:

Classe	Registros	Proporção
Treino D	92	30,7%
Treino C	80	26,7%
Treino A	74	24,7%
Treino B	54	18,0%

Desbalanceamento leve: razão entre a classe mais frequente (Treino D) e a mais rara (Treino B) = 1,7:1. Não é grave, mas o suficiente para exigir cuidado na modelagem (ver tabela de diagnóstico). O gráfico grafico_desbalanceamento.png, gerado no notebook, mostra essa distribuição.

3. Tabela de diagnóstico

Problema encontrado / onde aparece	Grav.	Ação de tratamento proposta e justificativa	Quando
Base 100% simulada — perfis e rótulos gerados por regra, não observados em alunos reais. Toda a base.	Alta	Substituir/complementar por dados reais (formulário + rótulo validado por profissional de educação física). Enquanto isso, tratar as métricas do modelo como prova de conceito, não como desempenho real. Escolhido em vez de "seguir apenas com a base simulada" porque a validade externa é o maior risco do projeto.	Ao obter acesso a dados reais (Encontro 8 em diante)
Ausência de nulos é artificial. Todas as colunas (0/300).	Média	Não há o que corrigir agora; construir o pipeline de ingestão já prevendo nulos. Para nulos futuros: imputar restricao_fisica ausente como "Nenhuma" (valor mais provável e conservador) e sinalizar a linha; descartar a linha apenas se faltar o objetivo (feature central). Preencher foi preferido a descartar porque a base é pequena e cada linha conta.	Encontro 8
Ruído de rótulo de 8% — 24 registros com treino_recomendado que contradiz a regra de geração. Coluna treino_recomendado (24 linhas identificadas no notebook).	Média	Manter os 24 registros — representam exceções legítimas que o modelo precisa tolerar. Documentar que a acurácia máxima esperada é ~92% e não perseguir ajuste fino sobre eles. Alternativa descartada: remover as 24 linhas — rejeitada porque eliminaria justamente a variabilidade que o modelo deve aprender a suportar.	Encontro 9 (treino/avaliação)
Desbalanceamento leve — Treino B 18,0% vs Treino D 30,7% (razão 1,7:1). Coluna treino_recomendado.	Média	Usar class_weight="balanced" na Árvore de Decisão, stratify no split treino/teste e avaliar por F1-macro e matriz de confusão, não por acurácia. Alternativa descartada: oversampling/SMOTE — desnecessário para desbalanceamento tão leve e arriscado com poucas linhas.	Encontro 8 (split) e 9 (treino)
nivel_experiencia sem acento ("Avancado", "Intermediario") divergindo do dicionário. Coluna nivel_experiencia.	Média	Definir vocabulário controlado e aplicar mapeamento de padronização na ingestão, para garantir join consistente quando dados reais (provavelmente acentuados) entrarem.	Encontro 8
Variáveis ordinais tratadas como texto nominal. Colunas nivel_experiencia e equipamento_disponivel.	Média	Codificação ordinal explícita (Iniciante<Intermediário<Avançado; Nenhum<Limitado<Completo) com ordem definida, preservando a informação de ordem que a Árvore pode usar nos cortes. Preferida a one-hot porque one-hot descartaria a ordem.	Encontro 8
Divergência dicionário × dado: idade documentada "16–65", base vai de 16 a 51. Coluna idade / dicionário do README.	Baixa	Corrigir o dicionário para a faixa real observada (16–51) agora; ao coletar dados reais, buscar cobertura de alunos 50+.	Encontro 5 (doc) / coleta real
19 registros de menores (16–17 anos) e apenas 2 registros com 50+ anos. Coluna idade.	Baixa	Manter. Em dados reais, exigir campo de consentimento do responsável para menores e monitorar o desempenho do modelo por faixa etária, dada a sub-representação dos extremos.	Encontro 8/9
7 combinações perfil+rótulo repetidas (14 linhas), ignorando aluno_id. Base inteira exceto aluno_id.	Baixa	Nenhuma remoção — são colisões esperadas de um perfil de baixa cardinalidade, não duplicatas de coleta. Registrar o teste para reaplicar em dados reais, onde indicaria cadastro duplicado.	Encontro 8 (só se reaparecer em dados reais)
Sub-representação estrutural: "sem equipamento" = 7,3% da base, e 20 de 22 desses casos têm rótulo fixo Treino D pela regra. Cruzamento equipamento_disponivel × treino_recomendado.	Média	Na coleta real, definir cota mínima para alunos que treinam em casa; enquanto isso, declarar explicitamente que o modelo não personaliza bem para esse grupo e restringir o escopo de uso.	Coleta real / Encontro 8

4. Discussão de vieses

Viés identificado: viés de amostragem combinado com viés de rotulagem no grupo "sem acesso a equipamento".

Tipo: amostragem (o grupo é apenas 7,3% da base) somado a rotulagem (a regra equipamento = "Nenhum" → Treino D foi uma decisão de projeto do estudante, não a avaliação de um profissional de educação física).

- Quem está representado: o "aluno típico de academia paga" — jovem adulto (idade média 29), iniciante, sem restrição física, com acesso a equipamento completo ou parcial (92,7% da base).
- Quem ficou de fora: quem treina em casa sem equipamento, pessoas com 50+ anos (2 registros), pessoas com mais de uma restrição física ao mesmo tempo (a coluna só admite uma), e alunos com disponibilidade extrema (1 ou 6 dias, ~5% cada).
- Decisão humana embutida: o rótulo treino_recomendado não veio de avaliações reais — é a saída de uma função de regras escrita pelo próprio estudante. O modelo vai aprender e reproduzir as opiniões dessa função, inclusive "sem equipamento = sempre Treino D", independentemente do objetivo do aluno.
- Como afeta o modelo: para os ~7% sem equipamento, a Árvore de Decisão aprende um único caminho (→ Treino D) e nunca diferencia quem quer emagrecer de quem quer hipertrofia treinando em casa. Como esse grupo correlaciona com menor poder aquisitivo, o sistema entrega a pior personalização justamente a quem tem menos acesso a acompanhamento profissional pago.
- Quem é prejudicado se o modelo errar: o aluno iniciante (não tem repertório para perceber que a recomendação é inadequada) e o aluno com restrição física (custo do erro = risco de lesão).

Como reduzir ou ao menos documentar: (a) na coleta real, sobreamostrar o grupo sem equipamento (cota mínima) e usar mais de um profissional como fonte de rótulo; (b) na modelagem, avaliar métricas separadas por subgrupo de equipamento_disponivel, não apenas a métrica global; (c) registrar de forma visível para quem usar a ferramenta que o modelo é confiável para o perfil coberto e não para os grupos sub-representados; (d) coletar restricao_fisica como múltipla escolha.

5. Síntese

A base cumpre bem o papel de ponto de partida, mas seu problema central não é ausência, duplicata ou inconsistência de digitação — é ser 100% simulada, com rótulo gerado por regras. Os problemas técnicos encontrados são de gravidade baixa a média e têm tratamento previsto para o Encontro 8. O ponto de atenção mais sério para a AP1 e para o resto do projeto é o de representatividade: grupos inteiros (sem equipamento, idosos) estão sub-representados e, no caso de "sem equipamento", a própria regra de geração colapsa a saída numa única classe.